

Universidad Técnica Nacional

Sede Regional de San Carlos

Minería de Datos

III Cuatrimestre 2026

Diseño e implementación de un Data Warehouse para Invacom Inc S.A.

Profesor:

Freddy Gerardo Rocha Boza

Estudiantes:

Maikel Josue Chaves Salas

Xavier Gerardo Fernandez Zuñiga

Nayely De Los Ángeles Vega Murillo

Álvaro Víctor Zamora

11 de noviembre de 2026

Tabla de contenido

Introducción 3

Enlace al repositorio Git 4

Enunciado del problema 7

Objetivo general 8

Objetivos específicos 9

Descripción de la solución 10

- Requisitos del negocio y usuarios 10
- Fuentes de datos y calidad 10
- Arquitectura y proceso ETL 10
- Modelo dimensional y granularidad 11
- Validación y visualización 11

Diagrama del modelo dimensional 12

Introducción

El análisis de datos es fundamental para la toma de decisiones empresariales, ya que permite identificar tendencias, evaluar resultados y mejorar los procesos organizacionales. Por esta razón, las empresas necesitan herramientas que faciliten la transformación de grandes cantidades de datos en información útil.

Invacom Inc S.A. es una empresa distribuidora de alimentos que opera con clientes en 21 países. Su información se almacena en una base de datos transaccional en PostgreSQL, la cual permite gestionar las operaciones diarias, pero presenta limitaciones para realizar análisis históricos y generar reportes de manera eficiente.

El presente proyecto tiene como objetivo desarrollar un *Data Warehouse* en SQL Server, utilizando Apache Spark (PySpark) para los procesos de extracción, transformación y carga (ETL). Además, se implementa un modelo dimensional que facilita el análisis de ventas, clientes, productos, empleados y logística mediante tablas dinámicas en Excel.

Se utilizan GitHub y la metodología Scrum para organizar las actividades, controlar las versiones y evidenciar el trabajo colaborativo. De esta manera, se busca proporcionar una solución que facilite el acceso a la información y contribuya a mejorar la toma de decisiones de Invacom Inc S.A.

Enlace al repositorio Git

Repositorio del proyecto: https://github.com/Maikelch12/invacom-datawarehouse.git.

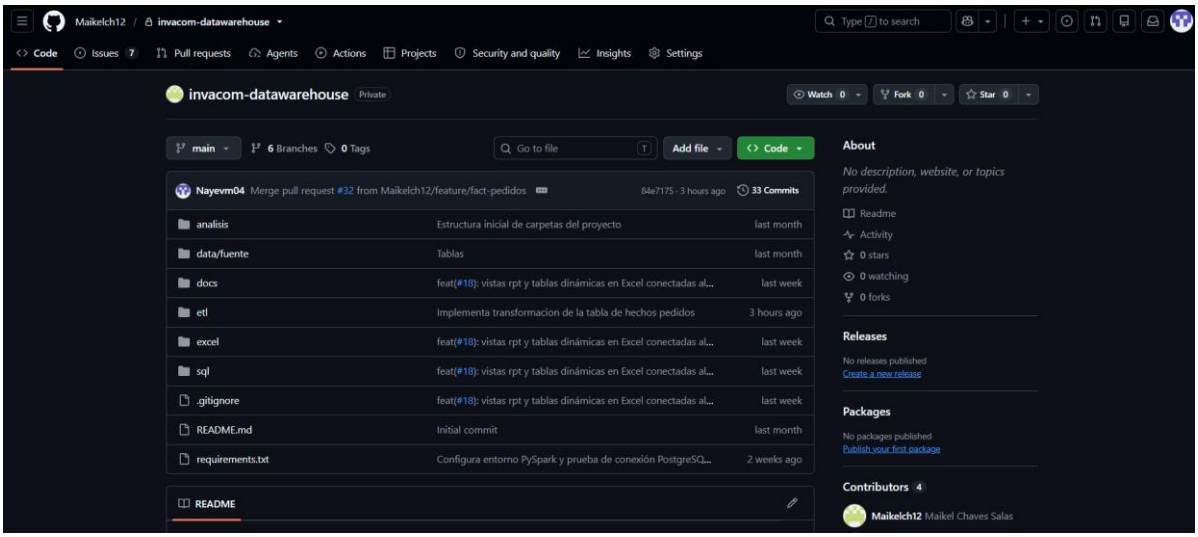


Figura 1. Estructura del repositorio y evidencia del historial de commits. Fuente: captura proporcionada por el equipo.

Las capturas del historial muestran contribuciones distribuidas entre octubre y noviembre de 2026, con tareas relacionadas con la base fuente, conexiones PostgreSQL–PySpark–SQL Server, dimensiones, hechos y reportes de Excel. También se observan pull requests fusionados y trabajo de varios colaboradores.



Figura 2. Ejemplos de commits de transformación de dimensiones y tabla de hechos. Fuente: captura proporcionada por el equipo.

La gestión de tareas se realiza mediante GitHub Issues y un proyecto visual denominado “Invacom DW - Scrum”. En la captura del tablero se distinguen las columnas Product Backlog, Sprint Backlog, En progreso, Revisión y Hecho; aparecen 21 tareas en Hecho y dos en En progreso. La evidencia corresponde al estado capturado, no a una auditoría completa de cada sprint.

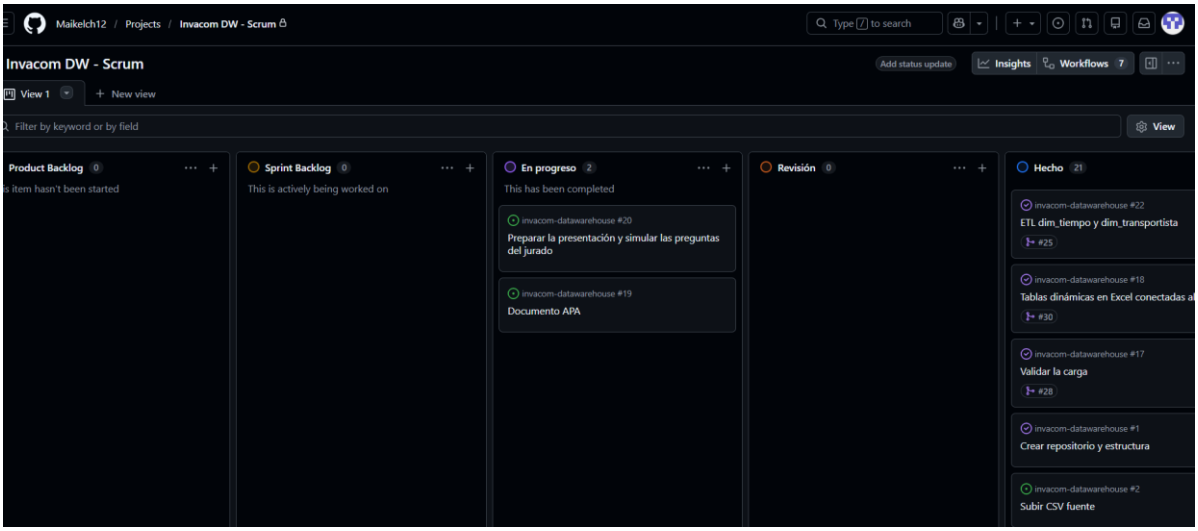


Figura 3. Issues cerrados relacionados con ETL, validación y Excel.

Fuente: captura proporcionada por el equipo.

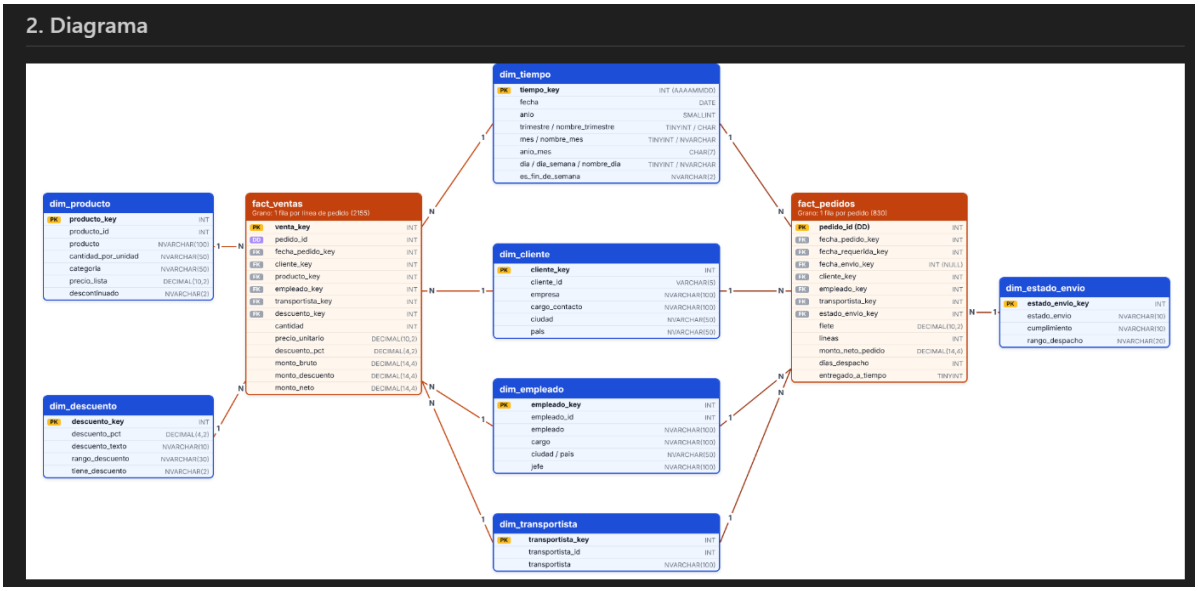


Figura 4. Tablero Kanban del proyecto Scrum. Fuente: captura proporcionada por el equipo.

Enunciado del problema

Invacom Inc S.A. es una empresa distribuidora de alimentos que administra su información mediante una base de datos transaccional en PostgreSQL. Aunque este sistema permite registrar y gestionar las operaciones diarias, presenta limitaciones para realizar análisis de ventas, clientes, productos y procesos logísticos.

Para obtener información sobre las ventas por país, categoría, empleado o período, es necesario consultar y relacionar diferentes tablas de la base de datos. Esto dificulta la generación de reportes y aumenta la dependencia del personal técnico, lo que limita el acceso oportuno a información relevante para la toma de decisiones.

Ante esta situación, surge la necesidad de implementar un *Data Warehouse* que centralice y organice los datos mediante un modelo dimensional. Esta solución permitirá analizar las ventas históricas, evaluar el impacto de los descuentos y consultar indicadores comerciales y logísticos de manera más sencilla, utilizando tablas dinámicas en Excel para apoyar la toma de decisiones de la empresa.

.

Objetivo general

Desarrollar un Data Warehouse para Invacom Inc S.A., poblado mediante un proceso ETL en Apache Spark desde la base operacional en PostgreSQL hacia un modelo dimensional en SQL Server, que permita a la gerencia analizar ventas, clientes, productos, empleados y logística mediante tablas dinámicas en Excel para apoyar la toma de decisiones.

Objetivos específicos

- Analizar las siete tablas de la base de datos fuente, identificando relaciones y problemas de calidad de datos y documentando las estrategias de limpieza.

- Diseñar un modelo dimensional con hechos a nivel de línea de pedido y de pedido, que responda las nueve preguntas de negocio.

- Implementar el ETL en PySpark para extraer, transformar y cargar los registros válidos desde PostgreSQL hacia SQL Server.

- Conciliar los conteos de pedidos y líneas y los importes netos entre la fuente y el almacén de datos.

- Construir tablas dinámicas de Excel conectadas al Data Warehouse para presentar indicadores comerciales y logísticos.

Descripción de la solución

Requisitos del negocio y usuarios

La junta directiva requiere estudiar la evolución de las ventas y los mercados de mayor aporte; ventas necesita evaluar empleados, clientes, descuentos y ticket promedio; logística necesita conocer cumplimiento, tiempos de despacho y fletes; compras necesita conocer productos, categorías y artículos descontinuados. Las nueve preguntas de negocio y sus indicadores se documentan en docs/01_requisitos_negocio.md.

Fuentes de datos y calidad

El origen es invacom_fuente en PostgreSQL, construido a partir de siete CSV: orders (830 registros), order_details (2.155), customers (91), products (77), categories (8), employees (9) y shippers (3). El perfilado del equipo documenta 21 pedidos sin shipped_date, un empleado sin reports_to, formatos mixtos de países, espacios duplicados, codificación LATIN1 en archivos de origen y descuentos atípicos. Estas situaciones requieren tratamientos diferentes: conservar los pedidos pendientes, mantener la jerarquía superior sin jefe y normalizar los textos sin alterar los importes históricos.

Arquitectura y proceso ETL

La solución emplea PostgreSQL como fuente, PySpark como motor de extracción y transformación mediante JDBC, SQL Server como destino dimensional y Excel como capa de consulta. Los módulos del repositorio separan las transformaciones por dimensión y tabla de hechos, mientras main.py actúa como punto de orquestación. El diseño distingue extracción, limpieza, cálculo de medidas, resolución de claves y carga.

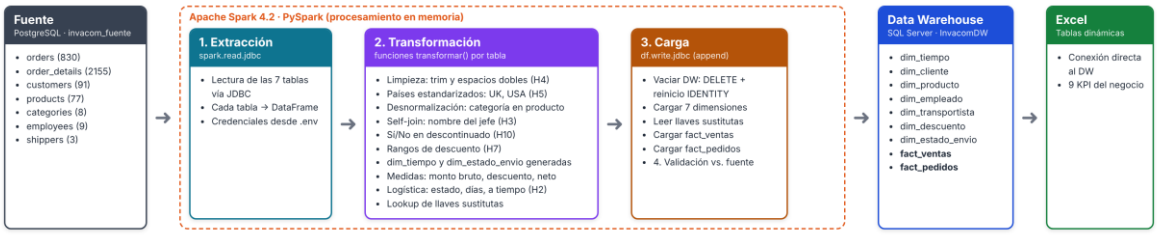


Figura 5. Flujo ETL incluido en el repositorio del equipo.

Fuente: docs/img/diagrama_flujo_etl.png.

Modelo dimensional y granularidad

El diseño utiliza siete dimensiones compartidas: dim_tiempo, dim_cliente, dim_producto, dim_empleado, dim_transportista, dim_descuento y dim_estado_envio. La tabla fact_ventas registra una fila por línea de pedido (2.155 filas esperadas), con cantidad, precio unitario, descuento y montos bruto, descontado y neto. La tabla fact_pedidos registra una fila por pedido (830 filas esperadas), con flete, número de líneas, monto neto del pedido y medidas de despacho. Esta separación evita multiplicar el flete de un pedido al analizar varias líneas de venta.

Validación y visualización

El repositorio incluye etl/validacion.py, sql/dw/02_consultas_analisis.sql y sql/dw/03_vistas_excel.sql. La documentación establece como valores de control 830 pedidos, 2.155 líneas y ventas netas de 1.265.793,04, así como 37 pedidos tardíos y 21 pendientes. Estos valores se presentan como controles documentados; la comprobación de una ejecución concreta requiere adjuntar resultados de consultas y registros de carga.

Se identificó el archivo excel/Invacom_DW_Tablas_Dinamicas.xlsx y la guía docs/06_tablas_dinamicas_excel.md. La documentación describe vistas de reporte y tablas dinámicas conectadas al almacén de datos. Queda pendiente incorporar capturas de las tablas dinámicas abiertas y su actualización para demostrar visualmente la conexión y los indicadores obtenidos.

Diagrama del modelo dimensional

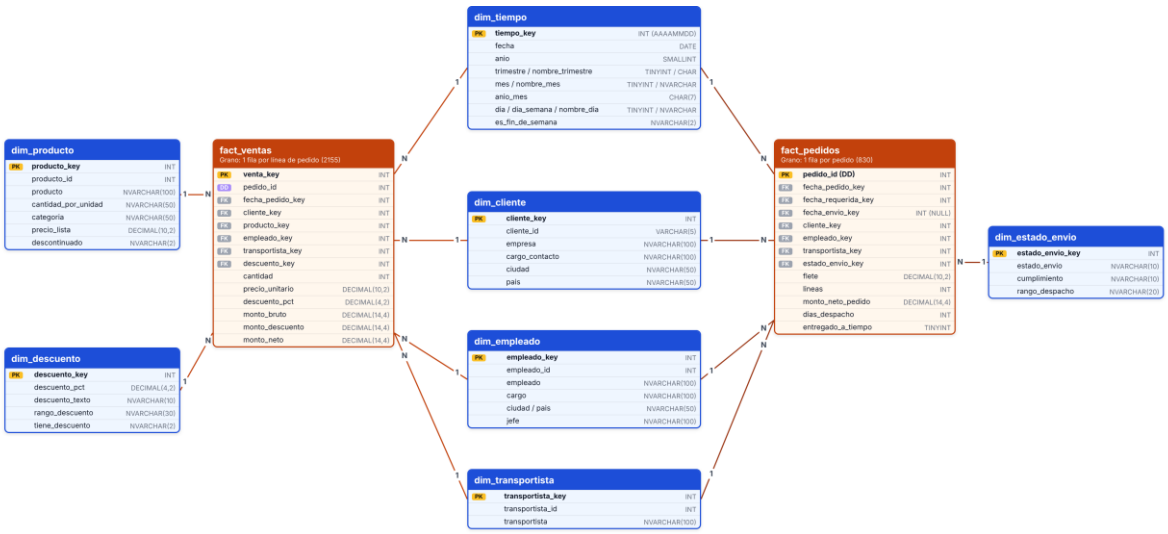


Figura 6. Diagrama dimensional original: dos tablas de hechos y siete dimensiones. Fuente: docs/img/diagrama_modelo_estrella.png.

El diagrama muestra las relaciones entre las claves sustitutas de las dimensiones y las claves foráneas de las tablas de hechos. El diseño es una constelación de hechos o esquema de galaxia compuesto por dos estrellas con dimensiones conformadas. Esta denominación describe con mayor precisión la solución que hablar de una sola estrella.