

Universidad Técnica Nacional

Sede Regional de San Carlos

Minería de Datos

III Cuatrimestre 2026

Diseño e implementación de un Data Warehouse para Invacom Inc S.A.

Profesor:

Freddy Gerardo Rocha Boza

Estudiantes:

Maikel Josue Chaves Salas

Xavier Gerardo Fernandez Zuñiga

Nayely De Los Ángeles Vega Murillo

Álvaro Víctor Zamora

11 de noviembre de 2026

Tabla de contenido

Introducción 4

Enlace al repositorio Git 5

Enunciado del problema 8

Objetivo general 9

Objetivos específicos 9

Descripción de la solución 10

Requisitos del negocio y usuarios 10

Usuarios, necesidades y preguntas de negocio 10

Fuentes de datos y calidad 11

Hallazgos y tratamiento de la calidad de datos 14

Arquitectura y proceso ETL 15

Modelo dimensional y granularidad 15

Justificación de la granularidad y las dimensiones 18

Validación y visualización 19

Visualización y análisis en Excel 20

Uso de Apache Spark en el proyecto 23

Extracción, transformación y carga de datos 24

Validación del ETL y control de calidad 25

Conexión de Excel al Data Warehouse 25

Indicadores clave de desempeño (KPI) 26

Resultados de las tablas dinámicas 26

Diagrama del modelo dimensional 28

Conclusión 29

Referencias 30

Introducción

El análisis de datos es fundamental para la toma de decisiones empresariales, ya que permite identificar tendencias, evaluar resultados y mejorar los procesos organizacionales. Por esta razón, las empresas necesitan herramientas que faciliten la transformación de grandes cantidades de datos en información útil.

Invacom Inc S.A. es una empresa distribuidora de alimentos que opera con clientes en 21 países. Su información se almacena en una base de datos transaccional en PostgreSQL, la cual permite gestionar las operaciones diarias, pero presenta limitaciones para realizar análisis históricos y generar reportes de manera eficiente.

El presente proyecto tiene como objetivo desarrollar un *Data Warehouse* en SQL Server, utilizando Apache Spark (PySpark) para los procesos de extracción, transformación y carga (ETL). Además, se implementa un modelo dimensional que facilita el análisis de ventas, clientes, productos, empleados y logística mediante tablas dinámicas en Excel.

Se utilizan GitHub y la metodología Scrum para organizar las actividades, controlar las versiones y evidenciar el trabajo colaborativo. De esta manera, se busca proporcionar una solución que facilite el acceso a la información y contribuya a mejorar la toma de decisiones de Invacom Inc S.A.

Enlace al repositorio Git

Repositorio del proyecto: https://github.com/Maikelch12/invacom-datawarehouse.git.

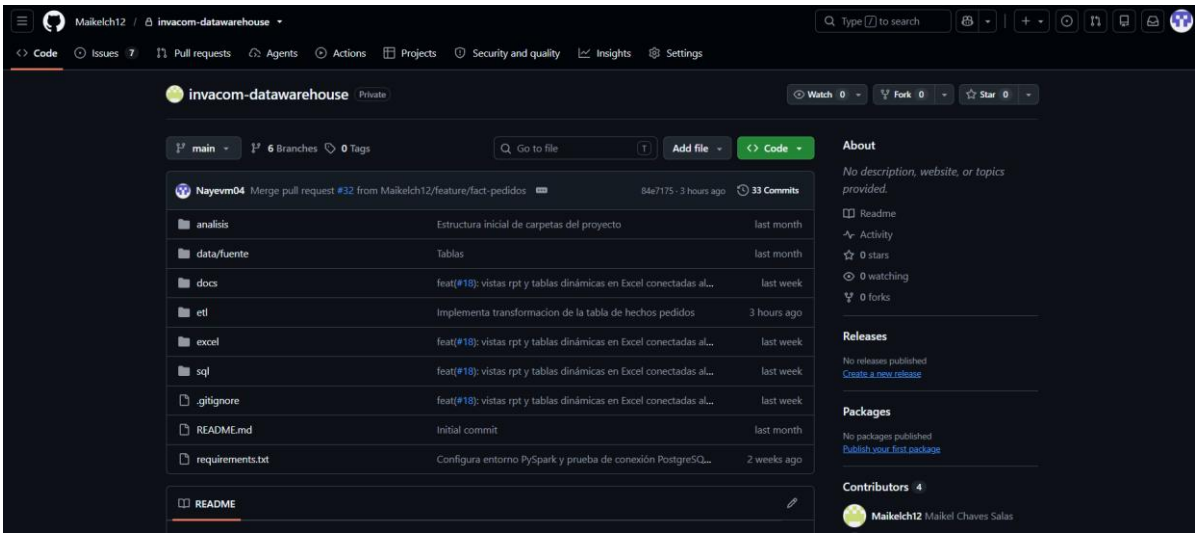


Figura 1. Estructura del repositorio y evidencia del historial de commits. Fuente: captura proporcionada por el equipo.

Las capturas del historial muestran contribuciones distribuidas entre octubre y noviembre de 2026, con tareas relacionadas con la base fuente, conexiones PostgreSQL–PySpark–SQL Server, dimensiones, hechos y reportes de Excel. También se observan pull requests fusionados y trabajo de varios colaboradores.

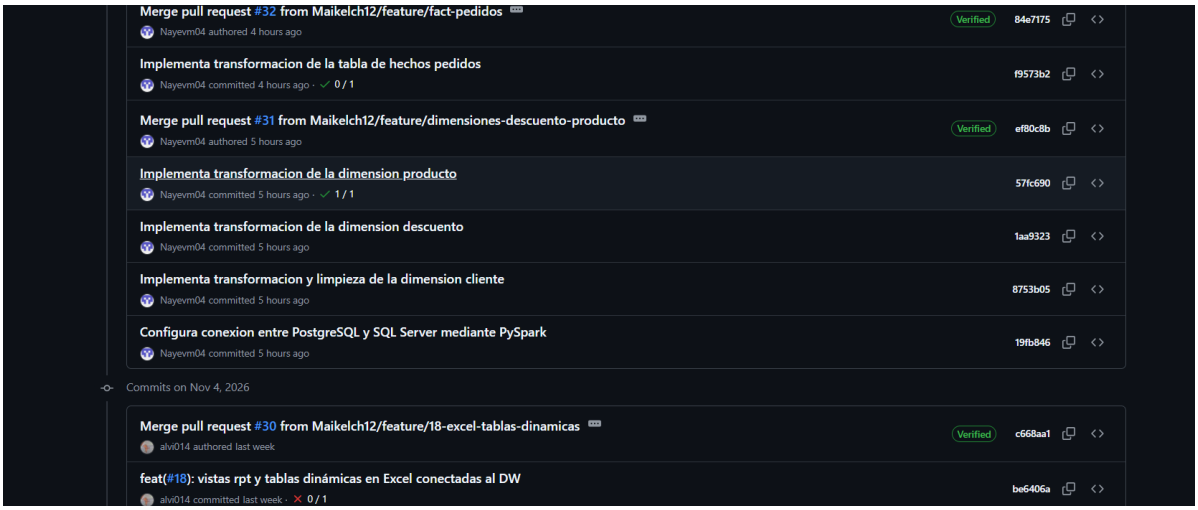


Figura 2. Ejemplos de commits de transformación de dimensiones y tabla de hechos. Fuente: captura proporcionada por el equipo.

La gestión de tareas se realiza mediante GitHub Issues y un proyecto visual denominado “Invacom DW - Scrum”. En la captura del tablero se distinguen las columnas Product Backlog, Sprint Backlog, En progreso, Revisión y Hecho; aparecen 21 tareas en Hecho y dos en En progreso. La evidencia corresponde al estado capturado, no a una auditoría completa de cada sprint.

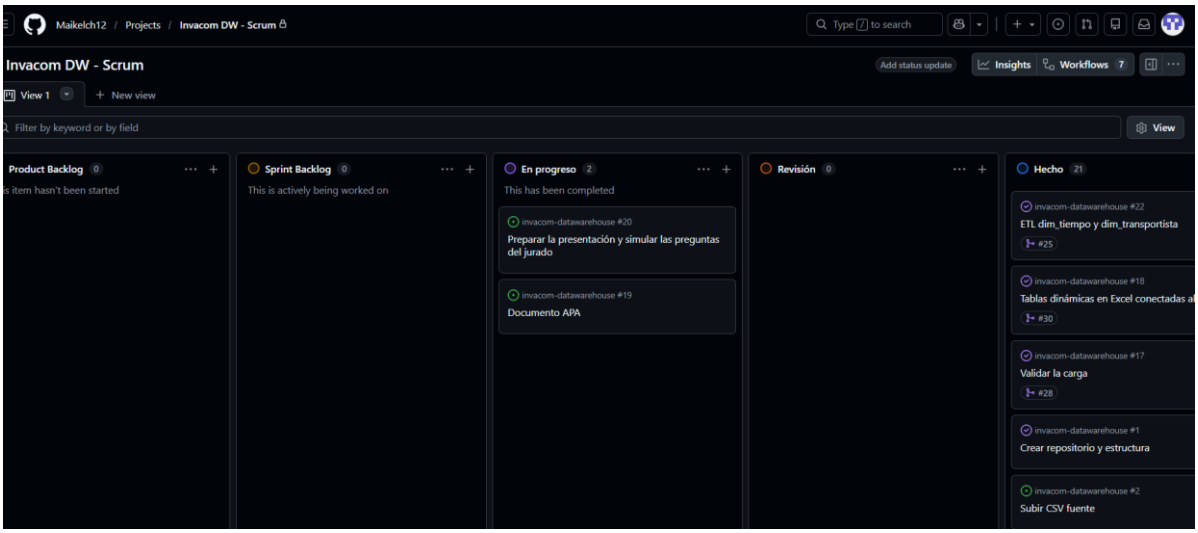


Figura 3. Issues cerrados relacionados con ETL, validación y Excel.

Fuente: captura proporcionada por el equipo.

Enunciado del problema

Invacom Inc S.A. es una empresa distribuidora de alimentos que administra su información mediante una base de datos transaccional en PostgreSQL. Aunque este sistema permite registrar y gestionar las operaciones diarias, presenta limitaciones para realizar análisis de ventas, clientes, productos y procesos logísticos.

Para obtener información sobre las ventas por país, categoría, empleado o período, es necesario consultar y relacionar diferentes tablas de la base de datos. Esto dificulta la generación de reportes y aumenta la dependencia del personal técnico, lo que limita el acceso oportuno a información relevante para la toma de decisiones.

Ante esta situación, surge la necesidad de implementar un *Data Warehouse* que centralice y organice los datos mediante un modelo dimensional. Esta solución permitirá analizar las ventas históricas, evaluar el impacto de los descuentos y consultar indicadores comerciales y logísticos de manera más sencilla, utilizando tablas dinámicas en Excel para apoyar la toma de decisiones de la empresa.

.

Objetivo general

Desarrollar un Data Warehouse para Invacom Inc S.A., poblado mediante un proceso ETL en Apache Spark desde la base operacional en PostgreSQL hacia un modelo dimensional en SQL Server, que permita a la gerencia analizar ventas, clientes, productos, empleados y logística mediante tablas dinámicas en Excel para apoyar la toma de decisiones.

Objetivos específicos

- Analizar las siete tablas de la base de datos fuente, identificando relaciones y problemas de calidad de datos y documentando las estrategias de limpieza.

- Diseñar un modelo dimensional con hechos a nivel de línea de pedido y de pedido, que responda las nueve preguntas de negocio.

- Implementar el ETL en PySpark para extraer, transformar y cargar los registros válidos desde PostgreSQL hacia SQL Server.

- Validar los registros cargados y los indicadores calculados mediante consultas y controles de consistencia.

- Construir tablas dinámicas de Excel conectadas al Data Warehouse para presentar indicadores comerciales y logísticos.

Descripción de la solución

Requisitos del negocio y usuarios

La solución responde a nueve preguntas de negocio agrupadas en evolución temporal de ventas, categorías y productos, clientes y países, desempeño de vendedores, ticket promedio, impacto de descuentos, cumplimiento de entregas, rendimiento de transportistas y productos descontinuados. Estos ejes permiten consultar el desempeño comercial y logístico desde distintas perspectivas.

Usuarios, necesidades y preguntas de negocio

Los usuarios previstos son la Junta Directiva (seguimiento trimestral de ventas y mercados), la Gerencia de Ventas (desempeño mensual de vendedores, clientes y descuentos), la Jefatura de Logística (cumplimiento de entregas y costos de transporte) y la Gerencia de Compras y Producto (categorías, productos y descontinuaciones). Las necesidades se traducen en nueve preguntas analíticas que guían el diseño del almacén.

Los nueve indicadores se organizan así: (1) ventas netas por mes, trimestre y año; (2) ingresos y unidades por producto y categoría; (3) ventas por país y los diez clientes principales; (4) ventas y cantidad de pedidos por vendedor; (5) ticket promedio por pedido; (6) monto descontado y proporción de líneas con descuento; (7) porcentaje de pedidos enviados a tiempo; (8) días promedio de despacho y flete por transportista; y (9) proporción de ventas de productos descontinuados.

Las ventas netas se calculan como precio unitario histórico × cantidad × (1 − descuento), utilizando order_details.unit_price y no el precio de lista actual. No se estiman márgenes de ganancia, existencias ni satisfacción del cliente porque la fuente carece de costos de compra, inventario y encuestas o devoluciones. El período de pedidos abarca del 4 de julio de 2013 al 6 de mayo de 2015; por ello, 2013 y 2015 son años parciales y no deben compararse como años completos.

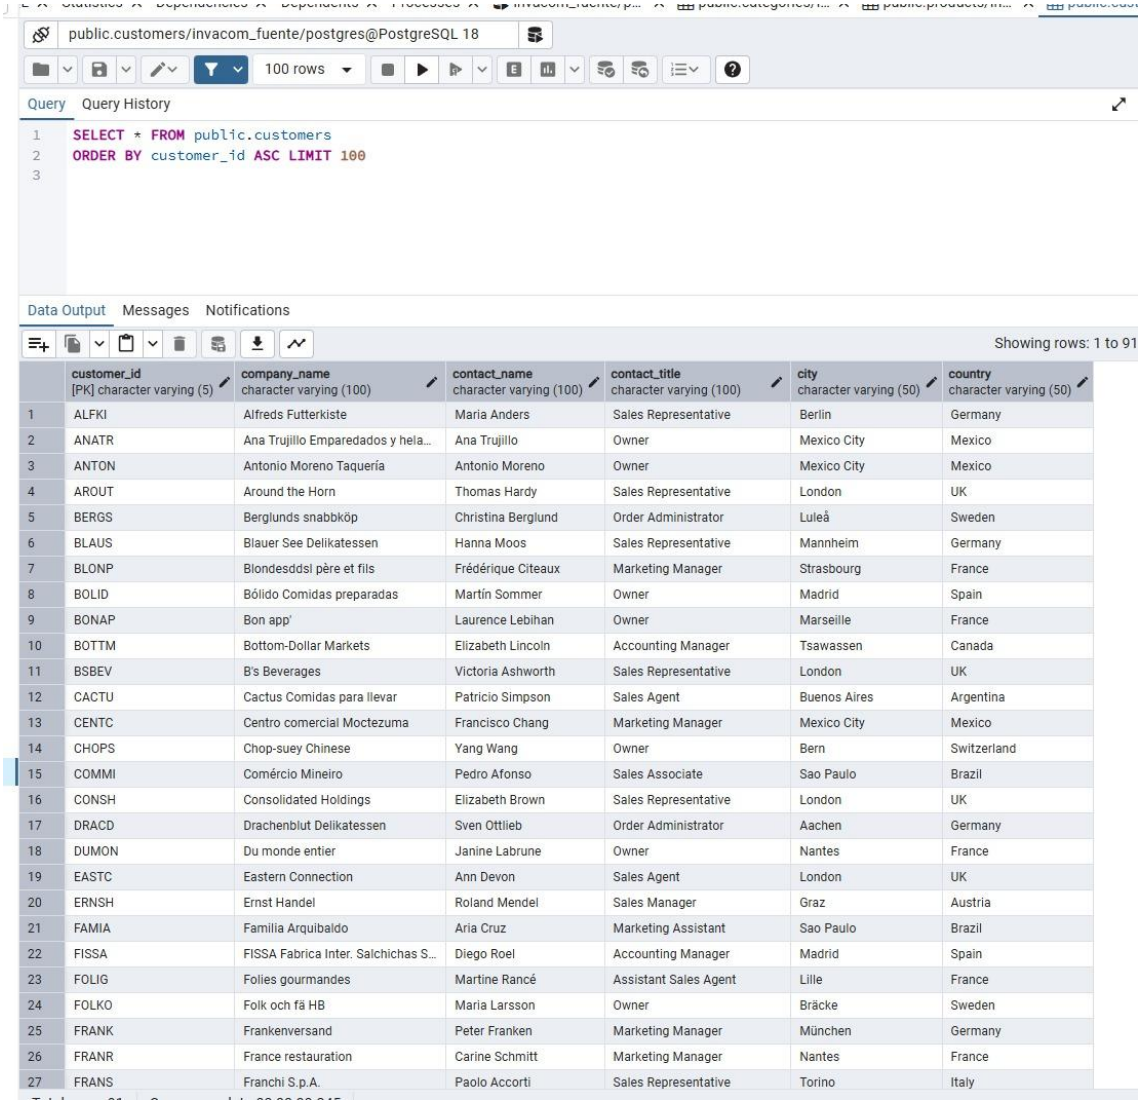
Fuentes de datos y calidad

La base de origen invacom_fuente, alojada en PostgreSQL 18, contiene siete tablas en el esquema public: categories, customers, employees, order_details, orders, products y shippers. La documentación técnica registra 91 clientes, 9 empleados, 77 productos, 8 categorías, 3 transportistas, 830 pedidos y 2.155 líneas de detalle.



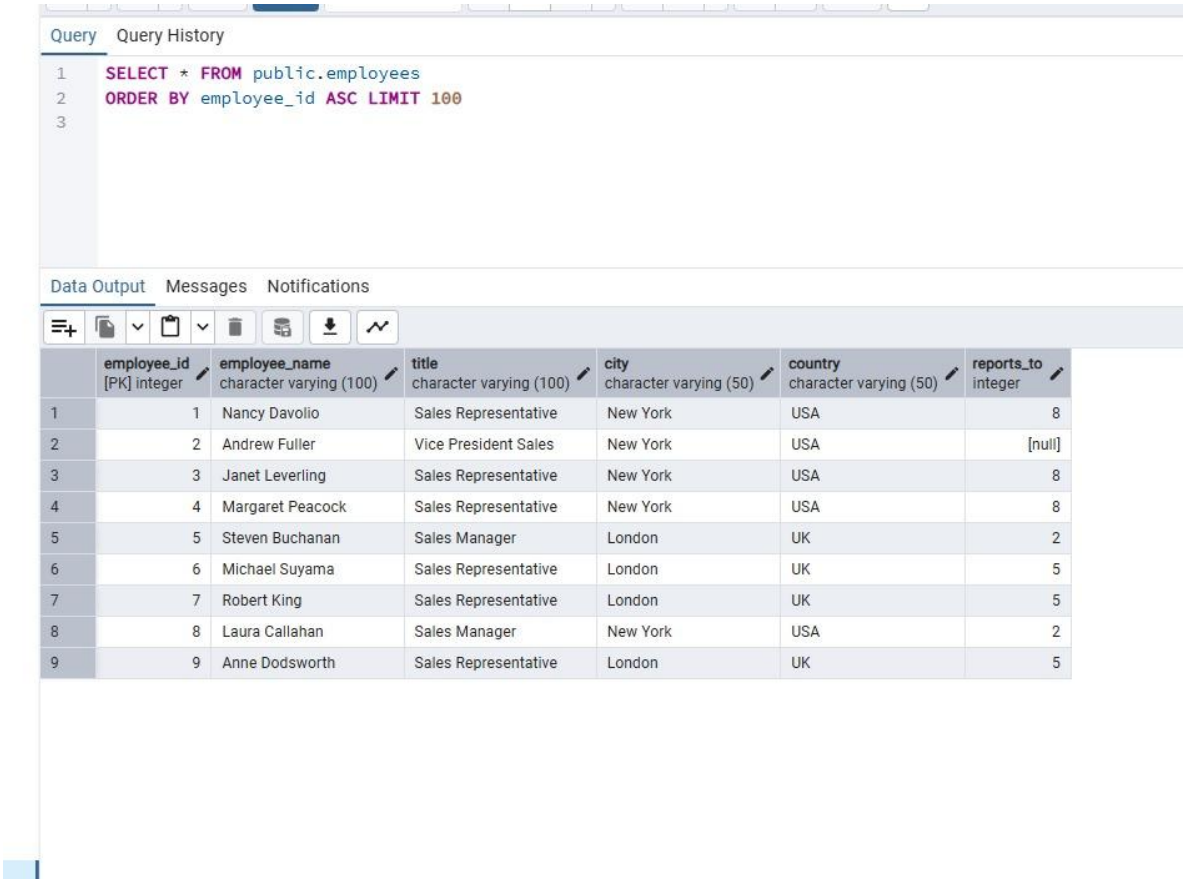
Figura 4. Estructura de las siete tablas de la base de datos invacom_fuente en PostgreSQL

Las consultas a customers y employees muestran el contenido operacional utilizado para poblar las dimensiones de clientes y empleados. En employees se observa al menos un valor nulo en reports_to, correspondiente a un empleado sin superior registrado; este caso requiere un tratamiento que preserve la información válida.



	customer_id [PK] character varying (5)	company_name character varying (100)	contact_name character varying (100)	contact_title character varying (100)	city character varying (50)	country character varying (50)
1	ALFKI	Alfreds Futterkiste	Maria Anders	Sales Representative	Berlin	Germany
2	ANATR	Ana Trujillo Emparedados y hela...	Ana Trujillo	Owner	Mexico City	Mexico
3	ANTON	Antonio Moreno Taquería	Antonio Moreno	Owner	Mexico City	Mexico
4	AROUT	Around the Horn	Thomas Hardy	Sales Representative	London	UK
5	BERGS	Berglunds snabbköp	Christina Berglund	Order Administrator	Luleå	Sweden
6	BLAUS	Blauer See Delikatessen	Hanna Moos	Sales Representative	Mannheim	Germany
7	BLONP	Blondesddsl père et fils	Frédérique Citeaux	Marketing Manager	Strasbourg	France
8	BOLID	Bólido Comidas preparadas	Martín Sommer	Owner	Madrid	Spain
9	BONAP	Bon app'	Laurence Lebihan	Owner	Marseille	France
10	BOTTM	Bottom-Dollar Markets	Elizabeth Lincoln	Accounting Manager	Tsawassen	Canada
11	BSBEV	B's Beverages	Victoria Ashworth	Sales Representative	London	UK
12	CACTU	Cactus Comidas para llevar	Patricio Simpson	Sales Agent	Buenos Aires	Argentina
13	CENTC	Centro comercial Moctezuma	Francisco Chang	Marketing Manager	Mexico City	Mexico
14	CHOPS	Chop-suey Chinese	Yang Wang	Owner	Bern	Switzerland
15	COMMI	Comércio Mineiro	Pedro Afonso	Sales Associate	Sao Paulo	Brazil
16	CONSH	Consolidated Holdings	Elizabeth Brown	Sales Representative	London	UK
17	DRACD	Drachenblut Delikatessen	Sven Ottlieb	Order Administrator	Aachen	Germany
18	DUMON	Du monde entier	Janine Labrune	Owner	Nantes	France
19	EASTC	Eastern Connection	Ann Devon	Sales Agent	London	UK
20	ERNSH	Ernst Handel	Roland Mendel	Sales Manager	Graz	Austria
21	FAMIA	Familia Arquibaldo	Aria Cruz	Marketing Assistant	Sao Paulo	Brazil
22	FISSA	FISSA Fabrica Inter. Salchichas S...	Diego Roel	Accounting Manager	Madrid	Spain
23	FOLIG	Folies gourmandes	Martine Rancé	Assistant Sales Agent	Lille	France
24	FOLKO	Folk och fä HB	Maria Larsson	Owner	Bräcke	Sweden
25	FRANK	Frankenversand	Peter Franken	Marketing Manager	München	Germany
26	FRANR	France restauration	Carine Schmitt	Marketing Manager	Nantes	France
27	FRANS	Franchi S.p.A.	Paolo Accorti	Sales Representative	Torino	Italy

Figura 5. Consulta de registros de clientes en PostgreSQL



	employee_id [PK] integer	employee_name character varying (100)	title character varying (100)	city character varying (50)	country character varying (50)	reports_to integer
1	1	Nancy Davolio	Sales Representative	New York	USA	8
2	2	Andrew Fuller	Vice President Sales	New York	USA	[null]
3	3	Janet Leverling	Sales Representative	New York	USA	8
4	4	Margaret Peacock	Sales Representative	New York	USA	8
5	5	Steven Buchanan	Sales Manager	London	UK	2
6	6	Michael Suyama	Sales Representative	London	UK	5
7	7	Robert King	Sales Representative	London	UK	5
8	8	Laura Callahan	Sales Manager	New York	USA	2
9	9	Anne Dodsworth	Sales Representative	London	UK	5

Figura 6. Consulta de registros de empleados en PostgreSQL

El perfilado documentado por el equipo también identifica fechas de envío faltantes, diferencias de formato en nombres de países y otras inconsistencias textuales. El proceso de transformación contempla la normalización de textos, la conservación de valores faltantes con significado operacional y el cálculo controlado de indicadores, sin modificar arbitrariamente los datos históricos.

Hallazgos y tratamiento de la calidad de datos

La fuente invacom_fuente contiene siete tablas: orders (830 registros), order_details (2.155), customers (91), products (77), categories (8), employees (9) y shippers (3). Se validaron las relaciones entre pedidos, detalles, productos, clientes, empleados, transportistas y categorías; la documentación técnica reporta ausencia de registros huérfanos y de duplicados en las claves.

Los hallazgos incluyen 21 pedidos sin fecha de envío (pendientes, no errores), un empleado sin jefe por ocupar el nivel superior de la jerarquía, espacios múltiples en textos, países abreviados como UK y USA, diferencias entre precios históricos y precios de lista, y descuentos atípicos que deben conservarse. También se detectaron dos clientes sin compras, nombres con posible error de digitación y valores 0/1 de productos descontinuados que se traducen a Sí/No.

El proceso conserva los pedidos pendientes en ventas, pero deja nulos los indicadores de días de despacho y entrega a tiempo, para excluirlos de los promedios de cumplimiento. Se normalizan espacios y nombres de países; se respetan precios pactados en cada línea; y no se corrigen nombres dudosos sin autorización. Los archivos fuente con codificación LATIN1 se importan adecuadamente para preservar caracteres especiales. Estas decisiones evitan perder información válida durante la transformación.

Arquitectura y proceso ETL

La arquitectura conecta PostgreSQL con PySpark a través de JDBC para extraer las tablas de origen. Posteriormente, los datos se limpian y transforman para construir dimensiones y hechos, y se cargan en SQL Server. El proyecto distribuye la lógica en módulos por entidad y utiliza un script principal de orquestación. Las vistas de reporte permiten que Excel consuma la información analítica.

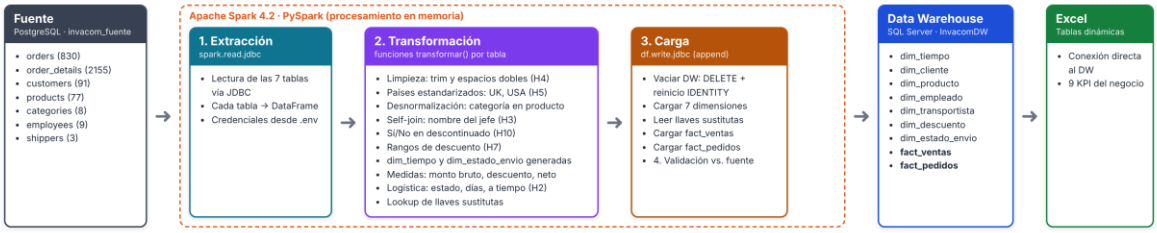


Figura 7. Flujo ETL incluido en el repositorio del equipo.

Fuente: docs/img/diagrama_flujo_etl.png.

Modelo dimensional y granularidad

El Data Warehouse InvacomDW se organiza en siete dimensiones: dim_cliente, dim_producto, dim_empleado, dim_transportista, dim_tiempo, dim_descuento y dim_estado_envio. Incluye dos tablas de hechos: fact_ventas, cuya granularidad es una línea de pedido, y fact_pedidos, cuya granularidad es un pedido. Esta separación evita duplicar medidas como el flete al consultar varias líneas del mismo pedido.

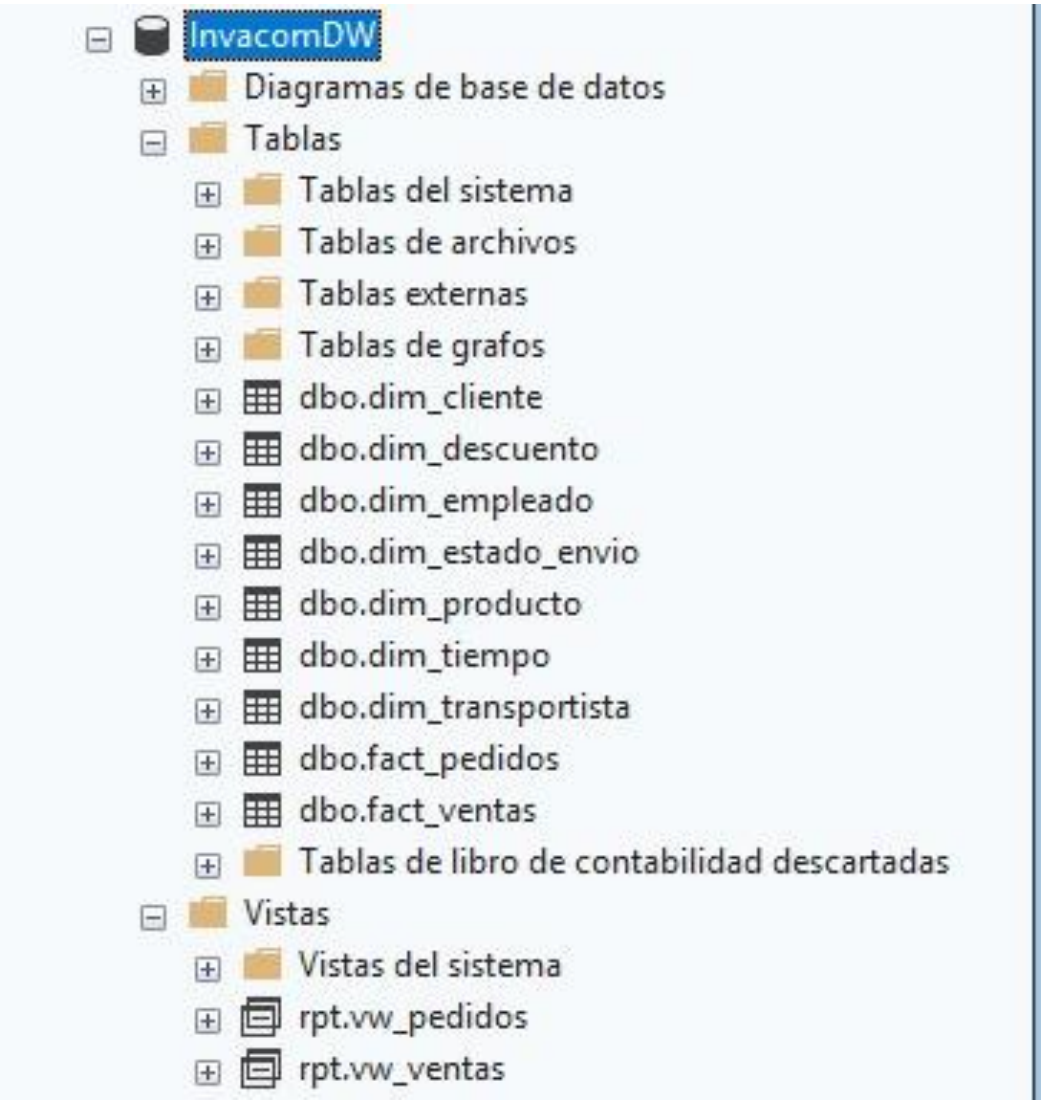
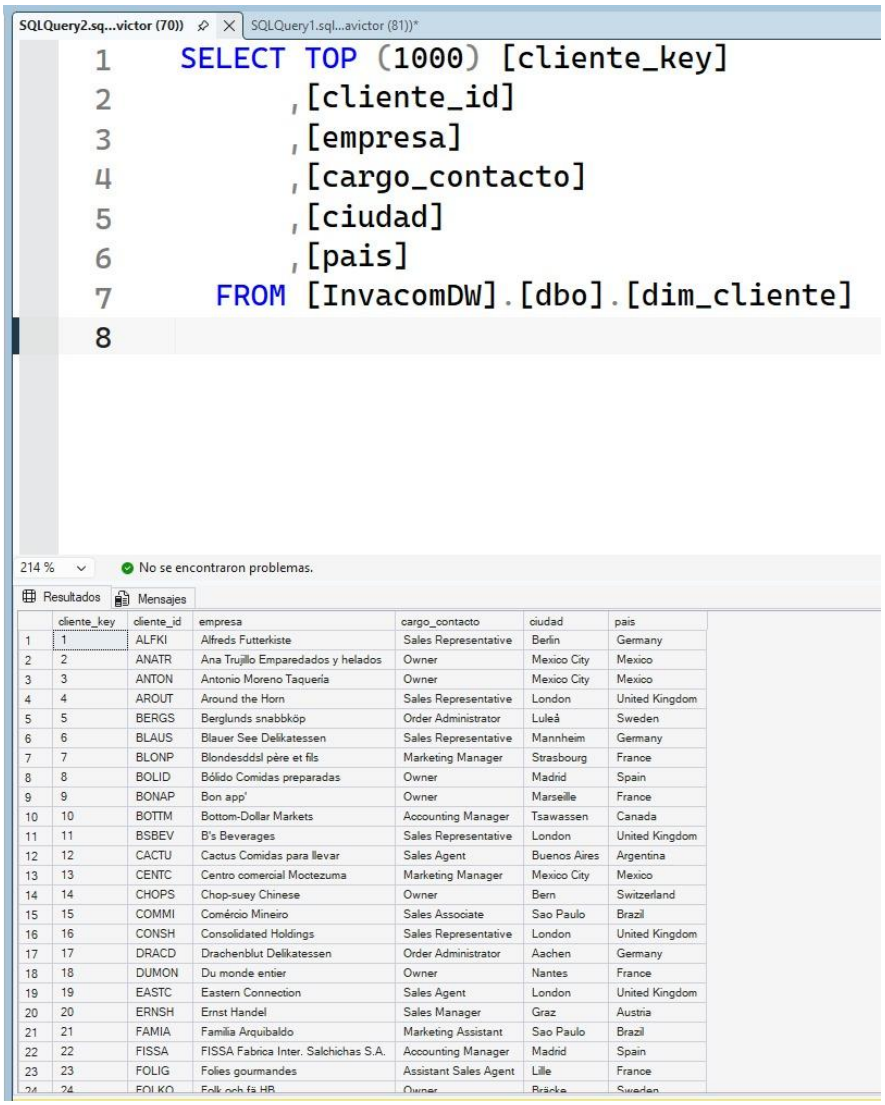


Figura 8. Tablas de dimensiones, hechos y vistas de reporte en SQL Server

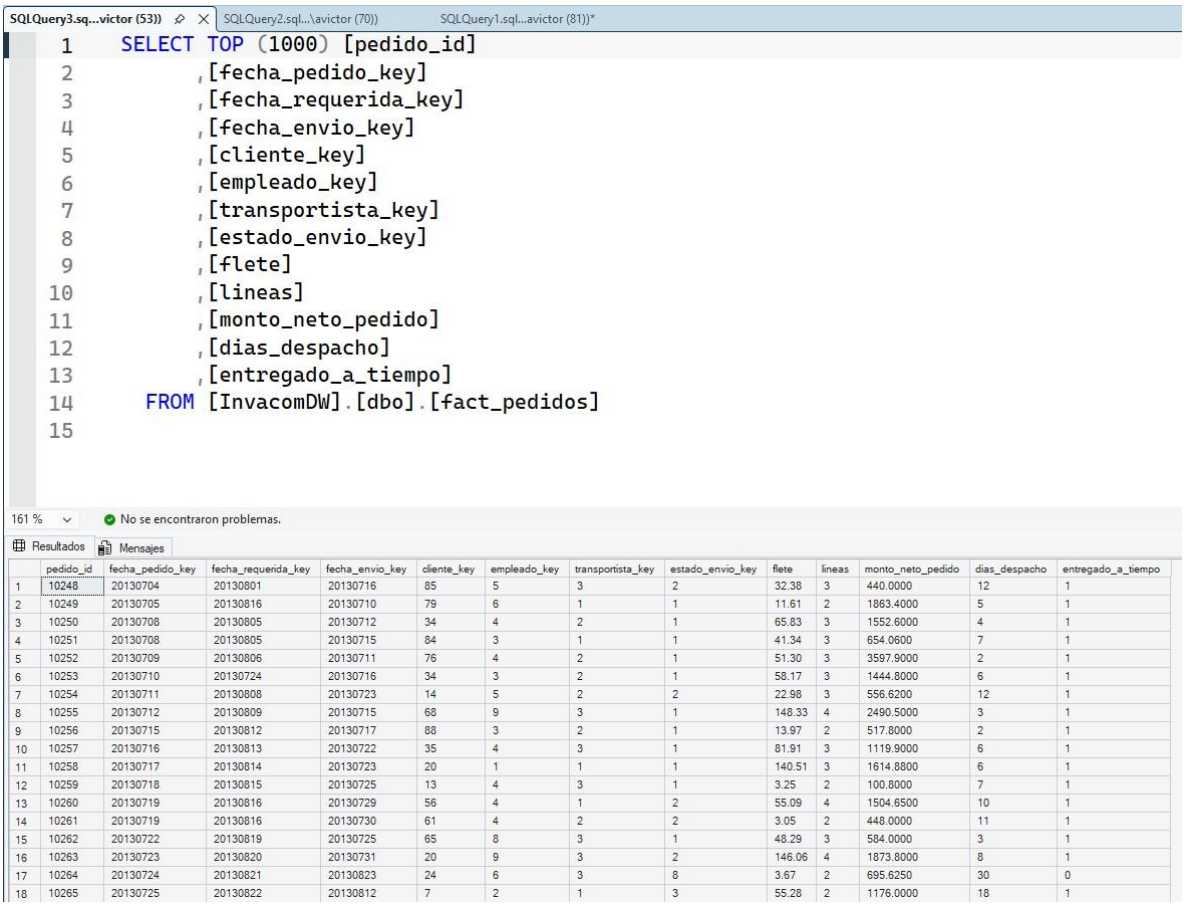
La dimensión de clientes almacena una clave sustituta y atributos descriptivos, como identificador original, empresa, cargo del contacto, ciudad y país. La siguiente consulta evidencia registros cargados en SQL Server y permite compararlos con la tabla de origen



	cliente_key	cliente_id	empresa	cargo_contacto	ciudad	pais
1	1	ALFKI	Alfreds Futterkiste	Sales Representative	Berlin	Germany
2	2	ANATR	Ana Trujillo Emparedados y helados	Owner	Mexico City	Mexico
3	3	ANTON	Antonio Moreno Taquería	Owner	Mexico City	Mexico
4	4	AROUT	Around the Horn	Sales Representative	London	United Kingdom
5	5	BERGS	Berglunds snabbköp	Order Administrator	Luleå	Sweden
6	6	BLAUS	Blauer See Delikatessen	Sales Representative	Mannheim	Germany
7	7	BLONP	Blondesddsl père et fils	Marketing Manager	Strasbourg	France
8	8	BOLID	Bólido Comidas preparadas	Owner	Madrid	Spain
9	9	BONAP	Bon app'	Owner	Marseille	France
10	10	BOTTM	Bottom-Dollar Markets	Accounting Manager	Tsawassen	Canada
11	11	BSBEV	B's Beverages	Sales Representative	London	United Kingdom
12	12	CACTU	Cactus Comidas para llevar	Sales Agent	Buenos Aires	Argentina
13	13	CENTC	Centro comercial Moctezuma	Marketing Manager	Mexico City	Mexico
14	14	CHOPS	Chop-suey Chinese	Owner	Bern	Switzerland
15	15	COMMI	Comércio Mineiro	Sales Associate	Sao Paulo	Brazil
16	16	CONSH	Consolidated Holdings	Sales Representative	London	United Kingdom
17	17	DRACD	Drachenblut Delikatessen	Order Administrator	Aachen	Germany
18	18	DUMON	Du monde entier	Owner	Nantes	France
19	19	EASTC	Eastern Connection	Sales Agent	London	United Kingdom
20	20	ERNSH	Ernst Handel	Sales Manager	Graz	Austria
21	21	FAMIA	Familia Arquibaldo	Marketing Assistant	Sao Paulo	Brazil
22	22	FISSA	FISSA Fabrica Inter. Salchichas S.A.	Accounting Manager	Madrid	Spain
23	23	FOLIG	Folies gourmandes	Assistant Sales Agent	Lille	France
24	24	FOLKO	Folk och fä HB	Owner	Bräcke	Sweden

Figura 9. Consulta de la dimensión dim_cliente en SQL Server

La tabla fact_pedidos incorpora claves de tiempo, cliente, empleado, transportista y estado de envío, junto con medidas como flete, cantidad de líneas, monto neto del pedido, días de despacho y entrega a tiempo. La consulta ejecutada muestra registros de esta tabla de hechos.



```
SELECT TOP (1000) [pedido_id]
      ,[fecha_pedido_key]
      ,[fecha_requerida_key]
      ,[fecha_envio_key]
      ,[cliente_key]
      ,[empleado_key]
      ,[transportista_key]
      ,[estado_envio_key]
      ,[flete]
      ,[lineas]
      ,[monto_neto_pedido]
      ,[dias_despacho]
      ,[entregado_a_tiempo]
  FROM [InvacomDW].[dbo].[fact_pedidos]
```

No se encontraron problemas.

Resultados | Mensajes

	pedido_id	fecha_pedido_key	fecha_requerida_key	fecha_envio_key	cliente_key	empleado_key	transportista_key	estado_envio_key	flete	lineas	monto_neto_pedido	dias_despacho	entregado_a_tiempo
1	10248	20130704	20130801	20130716	85	5	3	2	32.38	3	440.0000	12	1
2	10249	20130705	20130816	20130710	79	6	1	1	11.61	2	1863.4000	5	1
3	10250	20130708	20130805	20130712	34	4	2	1	65.83	3	1552.6000	4	1
4	10251	20130708	20130805	20130715	84	3	1	1	41.34	3	654.0600	7	1
5	10252	20130709	20130806	20130711	76	4	2	1	51.30	3	3597.9000	2	1
6	10253	20130710	20130724	20130716	34	3	2	1	58.17	3	1444.8000	6	1
7	10254	20130711	20130808	20130723	14	5	2	2	22.98	3	556.6200	12	1
8	10255	20130712	20130809	20130715	68	9	3	1	148.33	4	2490.5000	3	1
9	10256	20130715	20130812	20130717	88	3	2	1	13.97	2	517.8000	2	1
10	10257	20130716	20130813	20130722	35	4	3	1	81.91	3	1119.9000	6	1
11	10258	20130717	20130814	20130723	20	1	1	1	140.51	3	1614.8800	6	1
12	10259	20130718	20130815	20130725	13	4	3	1	3.25	2	100.8000	7	1
13	10260	20130719	20130816	20130729	56	4	1	2	55.09	4	1504.6500	10	1
14	10261	20130719	20130816	20130730	61	4	2	2	3.05	2	448.0000	11	1
15	10262	20130722	20130819	20130725	65	8	3	1	48.29	3	584.0000	3	1
16	10263	20130723	20130820	20130731	20	9	3	2	146.06	4	1873.8000	8	1
17	10264	20130724	20130821	20130823	24	6	3	8	3.67	2	695.6250	30	0
18	10265	20130725	20130822	20130812	7	2	1	3	55.28	2	1176.0000	18	1

Figura 10. Consulta de la tabla de hechos fact_pedidos en SQL Server

Justificación de la granularidad y las dimensiones

Se adopta un esquema dimensional de dos estrellas con dimensiones compartidas. fact_ventas registra una fila por línea de pedido (2.155 filas) y contiene cantidad, precio unitario, porcentaje de descuento, monto bruto, monto descontado y monto neto. fact_pedidos registra una fila por pedido (830 filas) y contiene flete, cantidad de líneas, monto neto del pedido, días de despacho y cumplimiento de entrega. Separar estas granularidades impide duplicar el flete o ponderar incorrectamente el cumplimiento según la cantidad de productos por pedido.

Las siete dimensiones son dim_tiempo (1.095 días de 2013 a 2015), dim_cliente (91), dim_producto (77), dim_empleado (9), dim_transportista (3),

dim_descuento (11) y dim_estado_envio (9). La categoría se integra en dim_producto y el jefe se resuelve dentro de dim_empleado, evitando uniones adicionales. La dimensión de tiempo participa en distintos roles como fecha del pedido, fecha requerida y fecha de envío.

Las dimensiones usan llaves sustitutas para independizar el DW de las claves operacionales, conservando las llaves de negocio para trazabilidad. pedido_id actúa como dimensión degenerada en los hechos. dim_descuento agrupa porcentajes en sin descuento, bajo (1–5 %), medio (6–15 %) y alto (16–25 %). dim_estado_envio reúne estado, cumplimiento y rango de despacho. El nivel de detalle permite sumar ventas por producto y agruparlas posteriormente por cliente, país o período.

Las medidas monetarias aditivas se suman, mientras que precio unitario y porcentaje de descuento no deben sumarse. El ticket promedio se calcula a nivel de pedido, los días de despacho se promedian y el indicador entregado_a_tiempo se promedia solo entre pedidos enviados. Los importes se conservan con cuatro decimales para facilitar la conciliación con la fuente.

Validación y visualización

Las capturas aportadas muestran consultas ejecutadas en las bases de origen y destino, así como resultados de Excel. El reporte temporal presenta 830 pedidos y ventas netas acumuladas por 1.265.793,04; el reporte de descuentos contabiliza 2.155 líneas. Estos valores coinciden con los controles registrados en la documentación del equipo y ofrecen evidencia de consistencia en los totales reportados.

Las capturas por sí solas no constituyen una prueba completa de la ejecución del pipeline ni de cada regla de limpieza. La validación técnica se complementa con los scripts y registros de ejecución disponibles en el repositorio.

Visualización y análisis en Excel

El libro Invacom_DW_Tablas_Dinamicas.xlsx contiene un menú con nueve preguntas de negocio. Según su portada, los reportes utilizan las vistas rpt.vw_ventas y rpt.vw_pedidos de SQL Server y están diseñados para actualizarse desde el Data Warehouse.

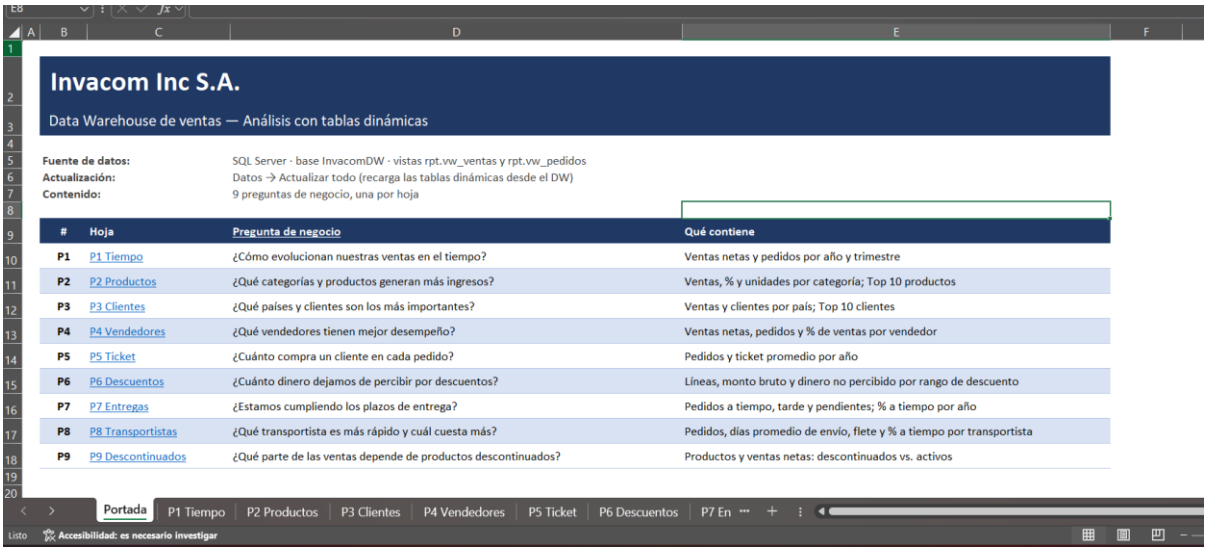


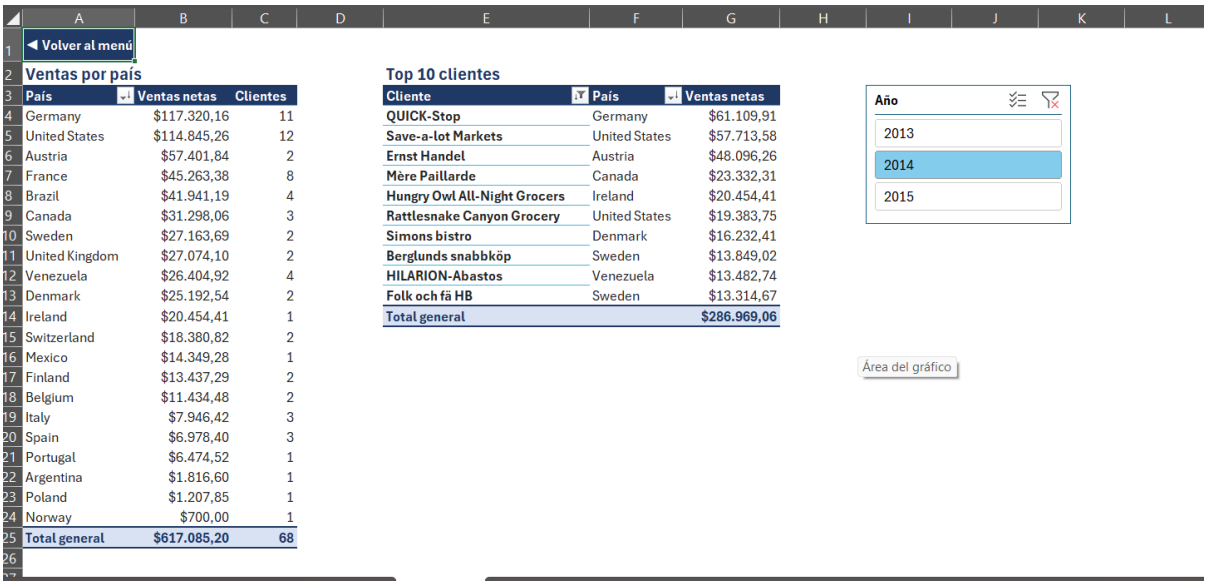
Figura 11. Menú de reportes y preguntas de negocio en Excel

La vista de evolución temporal presenta ventas netas y pedidos por año y trimestre. Se reportan 830 pedidos y ventas netas de 1.265.793,04. El mayor trimestre visible es el primero de 2015, con 298.491,55 en ventas netas y 182 pedidos. Los años extremos son parciales: 2013 comienza en julio y 2015 finaliza en mayo, por lo que sus cifras no deben compararse como años completos.



Figura 12. Tabla dinámica y gráfico de ventas netas y pedidos por trimestre

El análisis de clientes muestra ventas por país y un listado de los diez clientes con mayores ingresos. La captura utiliza un filtro de año en 2014: en ese período se observan 617.085,20 en ventas netas y 68 clientes. Alemania y Estados Unidos encabezan el listado por país en el período seleccionado. Este resultado no representa el total histórico, sino el año filtrado.



◄ Volver al menú

Ventas por país

País	Ventas netas	Clientes
Germany	$117.320,16	11
United States	$114.845,26	12
Austria	$57.401,84	2
France	$45.263,38	8
Brazil	$41.941,19	4
Canada	$31.298,06	3
Sweden	$27.163,69	2
United Kingdom	$27.074,10	2
Venezuela	$26.404,92	4
Denmark	$25.192,54	2
Ireland	$20.454,41	1
Switzerland	$18.380,82	2
Mexico	$14.349,28	1
Finland	$13.437,29	2
Belgium	$11.434,48	2
Italy	$7.946,42	3
Spain	$6.978,40	3
Portugal	$6.474,52	1
Argentina	$1.816,60	1
Poland	$1.207,85	1
Norway	$700,00	1
Total general	**$617.085,20**	**68**

Top 10 clientes

Cliente	País	Ventas netas
QUICK-Stop	Germany	$61.109,91
Save-a-lot Markets	United States	$57.713,58
Ernst Handel	Austria	$48.096,26
Mère Paillarde	Canada	$23.332,31
Hungry Owl All-Night Grocers	Ireland	$20.454,41
Rattlesnake Canyon Grocery	United States	$19.383,75
Simons bistro	Denmark	$16.232,41
Berglunds snabbköp	Sweden	$13.849,02
HILARION-Abastos	Venezuela	$13.482,74
Folk och fä HB	Sweden	$13.314,67
Total general		**$286.969,06**

Año

2013

2014

2015

Área del gráfico

Figura 13. Análisis de ventas por país y diez principales clientes con filtro de 2014

El reporte de descuentos clasifica 2.155 líneas de venta según rangos de descuento. Se observan 1.317 líneas sin descuento (61,1 %) y un monto total no percibido por descuentos de 88.665,55, frente a un monto bruto de 1.354.458,59. La diferencia coincide con las ventas netas acumuladas de 1.265.793,04, lo que refuerza la conciliación entre los indicadores presentados.

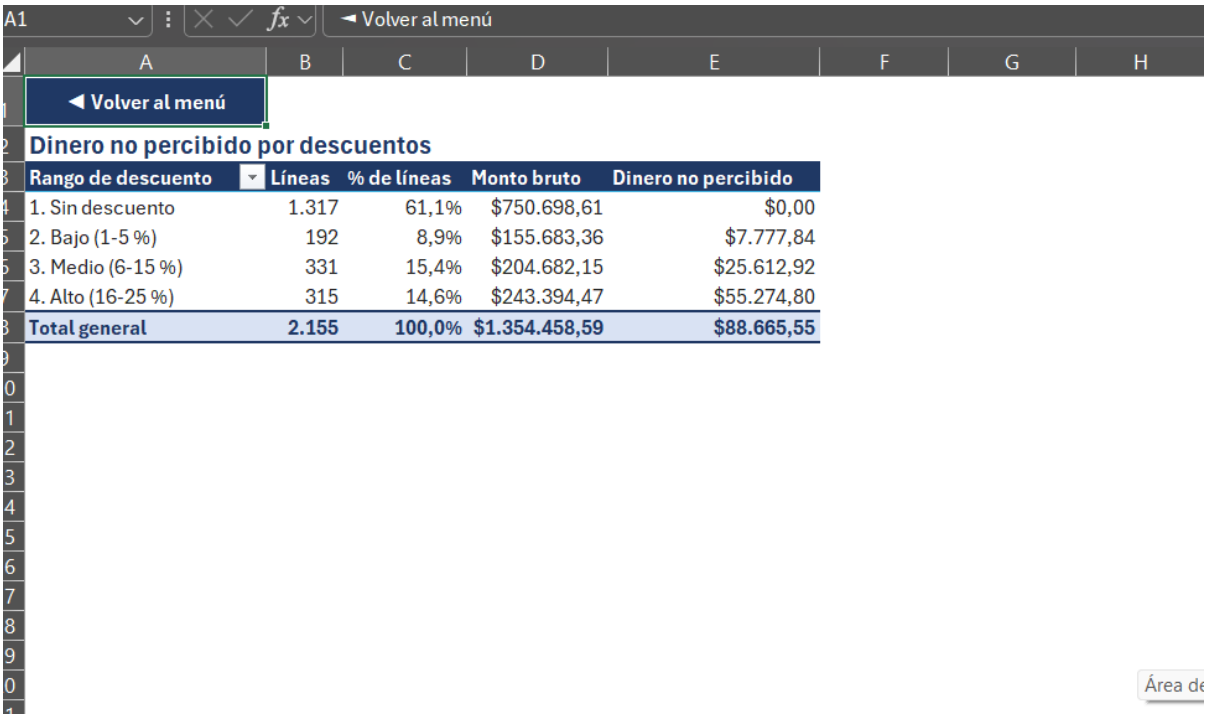


Figura 14. Distribución de líneas e importe no percibido por descuentos

Uso de Apache Spark en el proyecto

Apache Spark fue la herramienta principal para realizar el proceso ETL. Se utilizó mediante PySpark, que permite escribir las transformaciones en Python. La información se extrajo de PostgreSQL por medio de JDBC y se trabajó en DataFrames de Spark. Una vez preparados los datos, se enviaron a SQL Server mediante otra conexión JDBC. De esta forma, la limpieza y los cálculos se realizaron antes de almacenar la información en el Data Warehouse.

El código está organizado en la carpeta etl del repositorio. El archivo config.py prepara la sesión de Spark y las conexiones. Los archivos dim_cliente.py, dim_producto.py y los demás módulos contienen las transformaciones de cada dimensión. Los archivos fact_ventas.py y fact_pedidos.py preparan las tablas de hechos. Por último, main.py coordina el orden de ejecución y validacion.py comprueba los resultados. Esta separación facilita las pruebas y el trabajo del equipo.

Extracción, transformación y carga de datos

En la extracción se leen siete tablas: customers, products, categories, employees, shippers, orders y order_details. Spark recibe sus datos a través de JDBC. Se conserva el precio histórico de order_details, ya que representa el valor pactado en cada venta. El precio de products se utiliza únicamente como información descriptiva del producto.

En la transformación se eliminan espacios adicionales, se estandarizan los países UK y USA como United Kingdom y United States y se combinan productos con sus categorías. También se relaciona la tabla de empleados consigo misma para obtener el nombre del jefe. Se generan las dimensiones de tiempo, descuento y estado de envío, y se calculan las ventas brutas, descuentos, ventas netas y medidas de despacho.

Las ventas netas se obtienen multiplicando el precio unitario por la cantidad y aplicando el descuento de la línea. Para los pedidos, se suman las ventas de sus líneas y se calculan los días entre la fecha del pedido y la fecha de envío. Si un pedido aún no fue enviado, su fecha de envío y sus indicadores de cumplimiento permanecen nulos. De esta manera, el pedido sigue formando parte de las ventas, pero no distorsiona los indicadores de entregas.

El proyecto de Invacom Inc S.A. permitió transformar datos operacionales de PostgreSQL en información organizada para el análisis. Apache Spark, mediante PySpark, se utilizó para extraer, limpiar, relacionar y cargar los registros en SQL Server. El uso de siete dimensiones y dos tablas de hechos permite estudiar las ventas y la logística sin duplicar importes.

Las tablas dinámicas de Excel permiten responder nueve preguntas de negocio sobre ventas, clientes, productos, empleados, descuentos y entregas. Los reportes presentan 830 pedidos, 2.155 líneas y ventas netas por 1.265.793,04. La separación de las dos tablas de hechos facilita cálculos correctos de flete, ticket promedio y cumplimiento de entregas.

El proyecto muestra cómo un Data Warehouse puede facilitar la consulta de información que originalmente estaba distribuida en varias tablas transaccionales. Para futuras mejoras se recomienda automatizar las actualizaciones, incorporar cargas incrementales y ampliar las fuentes de datos. La documentación del ETL y de sus controles también permite dar mantenimiento al sistema y comprobar sus resultados.

La tabla fact_ventas tiene una fila por línea de pedido y contiene 2.155 registros. La tabla fact_pedidos tiene una fila por pedido y contiene 830 registros. Esta separación evita sumar varias veces el flete de un pedido con varios productos. También permite calcular correctamente el ticket promedio y el porcentaje de entregas a tiempo.

Validación del ETL y control de calidad

El diseño de validación compara la fuente con el Data Warehouse mediante conteos y montos. Los valores de control son 91 clientes, 77 productos, 9 empleados, 3 transportistas, 1.095 fechas, 11 descuentos y 9 estados de envío. Para las tablas de hechos se esperan 2.155 líneas de venta y 830 pedidos. El total de ventas netas de referencia es 1.265.793,04. Además, se controlan 21 pedidos pendientes y 37 pedidos enviados después de la fecha requerida.

Las capturas de SQL Server y Excel muestran datos cargados y totales de los reportes. La documentación técnica describe las comprobaciones automáticas de validacion.py, que muestra OK o ERROR según cada comparación. Para demostrar la ejecución completa ante el profesor, es recomendable presentar también una captura de la consola con el resultado final del proceso.

Conexión de Excel al Data Warehouse

Los reportes se elaboraron en el archivo Invacom_DW_Tablas_Dinamicas.xlsx. Excel obtiene los datos desde SQL Server por medio de Power Query y las vistas rpt.vw_ventas y rpt.vw_pedidos. La primera ofrece información a nivel de línea de venta y la segunda a nivel de pedido. Las dos

se cargan al Modelo de datos de Excel y permiten actualizar los resultados desde la opción Datos > Actualizar todo.

Las vistas muestran nombres fáciles de interpretar y evitan que los usuarios tengan que relacionar directamente las tablas del modelo dimensional. También protegen la precisión de los resultados. Por ejemplo, el flete se consulta desde la vista de pedidos para no duplicarlo. Cuando se cuentan pedidos desde la vista de ventas, se utiliza el recuento distinto porque un pedido puede contener varias líneas.

Indicadores clave de desempeño (KPI)

El proyecto definió nueve preguntas de negocio que se responden con tablas dinámicas. Los indicadores son: evolución de ventas netas por período, ventas por categoría y producto, ventas por país y cliente, desempeño de vendedores, ticket promedio por pedido, monto descontado, porcentaje de entregas a tiempo, días de despacho y flete por transportista, y participación de productos descontinuados en las ventas.

Cada indicador responde a una necesidad concreta. La gerencia puede estudiar la evolución comercial y los mercados principales. Ventas puede revisar clientes, empleados y descuentos. Logística puede comparar transportistas y entregas. Compras puede identificar productos relevantes y evaluar la participación de artículos descontinuados.

> El ticket promedio se obtiene al dividir las ventas netas entre el número de pedidos, no entre el número de líneas. El cumplimiento se calcula solo sobre los 809 pedidos enviados, ya que los 21 pendientes no tienen resultado de entrega. Los años 2013 y 2015 son períodos parciales, por lo que las comparaciones de ventas deben considerar los meses disponibles.

Resultados de las tablas dinámicas

El reporte temporal presenta 830 pedidos y ventas netas por 1.265.793,04. En la tabla de descuentos se observan 2.155 líneas y un monto no percibido de

88.665,55. De esas líneas, 1.317 no presentan descuento, lo que equivale al 61,1 %. Estas cifras ayudan a explicar tanto el volumen de operaciones como el impacto de las políticas comerciales.

La captura de clientes corresponde al año 2014 y muestra ventas por 617.085,20, junto con un listado de los diez clientes principales. Este resultado debe interpretarse como un período filtrado y no como el total histórico. El libro también contiene hojas para productos, vendedores, ticket promedio, entregas, transportistas y productos descontinuados. Las nueve hojas se organizan desde un menú inicial que facilita la navegación.

Diagrama del modelo dimensional

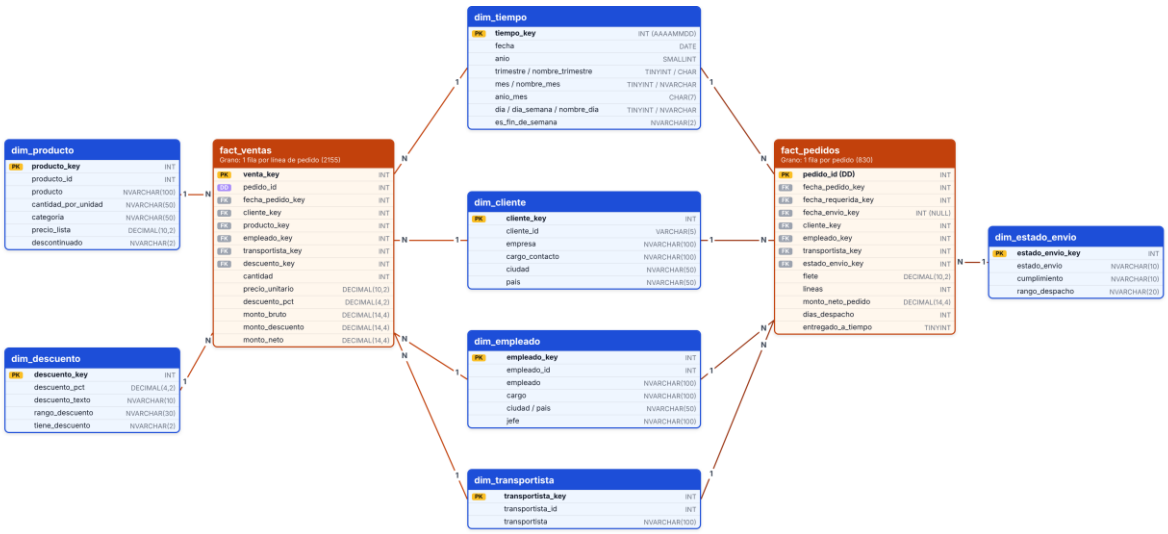


Figura 15. Modelo dimensional con dos tablas de hechos y siete dimensiones

El diseño se representa como una constelación de hechos: dos tablas de hechos relacionadas con dimensiones compartidas. Esta estructura permite responder tanto preguntas sobre líneas de venta como preguntas sobre pedidos y entregas, conservando el nivel de detalle adecuado para cada indicador.

Conclusión

El proyecto permitió integrar información operacional de Invacom Inc S.A. en un modelo dimensional orientado al análisis. La implementación combina PostgreSQL, PySpark, SQL Server y Excel para organizar datos de ventas, clientes, productos y entregas en una estructura que facilita la consulta de indicadores.

La separación de fact_ventas y fact_pedidos, junto con las siete dimensiones, responde a necesidades analíticas con granularidades diferentes. Las evidencias de SQL Server muestran registros cargados y las tablas dinámicas de Excel presentan resultados para 830 pedidos y 2.155 líneas, incluyendo ventas netas de 1.265.793,04 y descuentos por 88.665,55.

Los reportes permiten estudiar la evolución temporal de las ventas, identificar mercados y clientes relevantes y cuantificar el efecto de los descuentos. Como parte de una mejora continua, se recomienda conservar evidencias de ejecución del ETL, pruebas de calidad y actualizaciones de los reportes, además de mantener el historial de avances y la gestión de tareas en GitHub.

Referencias

Apache Software Foundation. (s. f.). Apache Spark: Unified engine for large-scale data analytics. https://spark.apache.org/

Apache Software Foundation. (s. f.). PySpark documentation. https://spark.apache.org/docs/latest/api/python/

GitHub. (s. f.). Invacom Data Warehouse [Repositorio de GitHub]. https://github.com/Maikelch12/invacom-datawarehouse

Microsoft. (s. f.). Crear una tabla dinámica para analizar datos de una hoja de cálculo. Soporte técnico de Microsoft. https://support.microsoft.com/es-es/excel/get-started/create-a-pivottable-to-analyze-worksheet-data

Microsoft. (s. f.). ¿Qué es Power Query? Microsoft Learn. https://learn.microsoft.com/es-es/power-query/power-query-what-is-power-query